

Classificação de Condições Maculares em Tomografia de Coerência Óptica com Descritores HOG e uma Rede Convolutacional Compacta

Jheam Storch Ross, Gabriel Zuany Duarte Vargas e Felipe Mattos
Departamento de Informática
Universidade Federal do Espírito Santo
Vitória, Brasil

I. INTRODUÇÃO

A mácula é a região central da retina responsável pela visão de detalhes. Alterações em sua estrutura podem comprometer de forma importante a visão central, mesmo quando a visão periférica permanece preservada. Este trabalho considera as quatro classes definidas no conjunto de dados de Kermany et al. [1]: neovascularização coroideana (CNV, do inglês *choroidal neovascularization*), edema macular diabético (DME, do inglês *diabetic macular edema*), drusas e retina normal. Elas não correspondem a quatro doenças: CNV é um processo patológico, drusas são achados anatômicos e a classe normal é uma referência. No contexto da base, a CNV é usada como representação da forma neovascular avançada da degeneração macular relacionada à idade (DMRI), caracterizada por membrana neovascular e possível fluido sub-retiniano. O DME decorre da retinopatia diabética e apresenta espessamento da retina associado ao acúmulo de fluido intrarretiniano. Drusas são depósitos sob o epitélio pigmentar da retina associados à DMRI, embora sua presença não implique necessariamente progressão para doença avançada. A classe normal apresenta contorno foveal preservado e ausência de edema ou fluido retiniano [1], [2].

A tomografia de coerência óptica (OCT, do inglês *optical coherence tomography*) é uma modalidade não invasiva e sem contato que emprega interferometria de baixa coerência para obter cortes ópticos de alta resolução dos tecidos [3]. Durante o exame, o paciente mantém a fixação enquanto o equipamento realiza uma varredura luminosa da retina. Cada corte transversal é denominado B-scan, e uma sequência desses cortes pode compor uma representação volumétrica. Em complemento ao exame clínico e à fotografia colorida de fundo de olho, a OCT permite observar separadamente as camadas retinianas e evidenciar fluido intrarretiniano ou sub-retiniano, que pode não ser claramente visível nessas outras modalidades [1]. Por isso, a OCT orienta a avaliação, o encaminhamento e o acompanhamento da resposta ao tratamento com agentes anti-VEGF (do inglês *anti-vascular endothelial growth factor*).

A Fig. 1 apresenta B-scans ilustrativos das quatro classes. A CNV e o DME podem produzir fluido e deformação das camadas, porém possuem mecanismos e padrões distintos; as drusas aparecem como elevações localizadas sob as camadas

externas da retina; e a amostra normal preserva a depressão foveal. As imagens também evidenciam variações de inclinação, ruído e morfologia existentes mesmo dentro de uma única classe, tornando a classificação automática um problema não trivial.

II. MOTIVAÇÃO

A deficiência visual possui impacto relevante no Brasil. A Pesquisa Nacional de Saúde de 2019 estimou que 3,4% da população com dois anos ou mais tinha muita dificuldade ou não conseguia enxergar, totalizando 6,978 milhões de pessoas [5]. Esse indicador descreve a limitação visual autorreferida, mas não identifica suas causas e, portanto, não pode ser atribuído diretamente às condições estudadas neste trabalho. Evidência etiológica mais específica é fornecida pelo São Paulo Eye Study: entre 3.678 participantes com 50 anos ou mais de uma região de renda baixa e média da cidade de São Paulo, doenças retinianas corresponderam a 35,3% dos olhos com acuidade visual apresentada inferior a 20/200 [6]. Trata-se, contudo, de uma amostra regional, não de uma estimativa nacional.

O componente diabético também representa uma população de risco expressiva. Uma revisão sistemática com 72 estudos e 29.527 adultos com diabetes estimou prevalência de retinopatia diabética de 36,28% no Brasil, com intervalo de confiança de 95% entre 32,66% e 39,97% [7]. A heterogeneidade elevada ($I^2 = 98\%$) exige cautela, e retinopatia diabética não equivale especificamente a DME, que pode ou não estar presente. Para a DMRI neovascular, a incorporação de aflibercepte e ranibizumabe ao Sistema Único de Saúde em 2021 reforça a relevância de identificar e acompanhar alterações tratáveis em tempo adequado [2].

Como um exame pode conter diversos B-scans, a análise manual demanda tempo especializado. Sistemas automáticos podem funcionar como apoio à triagem, destacando exames que requerem revisão prioritária e aumentando a consistência da leitura em cenários de grande volume [1], [8]. Essa função deve ser entendida como suporte à decisão: uma imagem isolada não contém histórico clínico, exame físico, informações sobre tratamento ou todas as aquisições do volume. Além disso, um modelo treinado nessa base multicêntrica internacional não está validado para uso clínico na população brasileira.




Figura 1. Exemplos ilustrativos das quatro classes: (a) neovascularização coroideana, (b) edema macular diabético, (c) drusas e (d) retina normal. Foram usadas as imagens de treinamento CNV-1676918-1, DME-1083927-1, DRUSEN-3424668-17 e NORMAL-1001772-12, sem recorte ou alteração de conteúdo. Fonte: versão 3 do conjunto de Kermay et al., disponibilizada sob licença CC BY 4.0 [4].

Nesse contexto, o objetivo do projeto é investigar se uma rede neural convolucional compacta, treinada do zero, consegue aprender representações úteis das quatro classes e superar uma referência clássica baseada em descritores de histogramas de gradientes orientados (HOG, do inglês *histograms of oriented gradients*) e regressão logística. A comparação privilegia um protocolo reproduzível, com separação por paciente e relato conjunto de desempenho global e por classe. Foi utilizada a versão 3 do subconjunto OCT de Kermay et al. [4], preservando-se o conjunto de teste oficial. A validação foi amostrada somente do conjunto de treino, em proporção de 15%, por agrupamento dos identificadores de paciente extraídos de nomes no padrão Kermay, como CNV-1016042-1.jpeg. O manifesto final foi validado para garantir interseções vazias dos conjuntos de identificadores de paciente entre treino, validação e teste. O resultado pretendido é uma análise experimental de métodos de classificação, e não um dispositivo diagnóstico.

III. TRABALHOS RELACIONADOS

Srinivasan et al. [9] apresentaram um dos antecedentes mais próximos da abordagem clássica considerada neste projeto. O método extrai descritores HOG multiescala de volumes OCT e os fornece a classificadores de máquinas de vetores de suporte. Em 45 sujeitos, divididos igualmente entre retina normal, DME e DMRI seca, o sistema identificou corretamente todos os volumes com DME e DMRI e 86,67% dos volumes normais. O número de classes, a escala da base e a avaliação por volume diferem do presente problema, impedindo comparação direta com acurácia por B-scan.

Kermay et al. [1] estabeleceram o benchmark de quatro classes utilizado neste trabalho. Os autores adaptaram uma Inception V3 pré-treinada no ImageNet, congelaram as camadas convolucionais e treinaram uma nova camada *softmax*. A acurácia multiclasse relatada foi 96,6% em 1.000 imagens de

633 pacientes independentes. Já sensibilidade e especificidade de 97,8% e 97,4% foram calculadas para a decisão binária de encaminhamento urgente, não como médias das quatro classes; essas métricas não devem ser comparadas diretamente a *recall* macro ou AUC multiclasse.

Trabalhos posteriores questionaram a necessidade de redes profundas pré-treinadas para esse domínio. Butola et al. [10] propuseram a LightOCT, com duas camadas convolucionais e uma camada totalmente conectada, treinada do zero. Na partição de teste com 1.000 imagens, a arquitetura alcançou 94,5% de acurácia, próxima de VGG-19 (93,3%) e Inception V3 (95,8%), mas abaixo de ResNet-101 (96,7%). Arefin et al. [11] também treinaram uma CNN sem transferência, formada por cinco camadas convolucionais e duas densas, e relataram 97,93% em 968 imagens de teste da versão 2 do conjunto.

Esses resultados precisam ser interpretados junto à análise de Tampu et al. [12]. Nos experimentos avaliados pelos autores, separar B-scans sem respeitar sujeito ou volume inflou a acurácia entre 5 e 30 pontos percentuais, pois cortes consecutivos compartilham estruturas e ruído. Na versão 2 de Kermay, 92% das imagens de teste possuíam identificadores de sujeitos também presentes no treino; na versão 3, não foi encontrada sobreposição de identificadores. Assim, o valor de Arefin et al. e outros resultados obtidos na versão 2 não constituem referências equivalentes a uma avaliação sem sobreposição por paciente.

Em uma direção mais próxima da aplicação clínica, De Fauw et al. [8] combinaram uma U-Net tridimensional, que converte o volume em mapas de tecido, com uma rede de diagnóstico e recomendação de encaminhamento. Foram usados 14.884 volumes de 7.621 pacientes, com teste em 997 pacientes, mais de 50 diagnósticos e quatro níveis de urgência. Essa tarefa clínica é mais ampla que as quatro classes deste trabalho e seus resultados não são diretamente comparáveis.

A Tabela I resume as diferenças centrais entre os estudos comparáveis.

Em conjunto, a literatura indica que arquiteturas compactas podem ser competitivas, mas não demonstra que transferência de aprendizado seja desnecessária em geral. Profundidade, número de parâmetros, versão da base, unidade de avaliação e estratégia de particionamento variam simultaneamente. Isso motiva a comparação controlada entre HOG e uma CNN compacta sob o mesmo manifesto com teste oficial preservado e separação validada por paciente, mantendo os experimentos exploratórios com transferência apenas como evidência secundária.

REFERÊNCIAS

- [1] D. S. Kermany, M. Goldbaum, W. Cai *et al.*, “Identifying medical diagnoses and treatable diseases by image-based deep learning,” *Cell*, vol. 172, no. 5, pp. 1122–1131.e9, 2018.
- [2] Comissão Nacional de Incorporação de Tecnologias no Sistema Único de Saúde, “Medicamentos para tratamento de pacientes com doença ocular que pode levar à cegueira são incorporados ao SUS,” Ministério da Saúde. Disponível em: gov.br/conitec, 2021, acesso em: 10 jul. 2026.
- [3] D. Huang, E. A. Swanson, C. P. Lin, J. S. Schuman, W. G. Stinson, W. Chang, M. R. Hee, T. Flotte, K. Gregory, C. A. Puliafito, and J. G. Fujimoto, “Optical coherence tomography,” *Science*, vol. 254, no. 5035, pp. 1178–1181, 1991.
- [4] D. Kermany, K. Zhang, and M. Goldbaum, “Large dataset of labeled optical coherence tomography (OCT) and chest X-ray images,” Mendeley Data, version 3, 2018, licença CC BY 4.0.
- [5] Instituto Brasileiro de Geografia e Estatística, “PNS 2019: país tem 17,3 milhões de pessoas com algum tipo de deficiência,” Agência de Notícias IBGE. Disponível em: agenciadenoticias.ibge.gov.br, 2021, acesso em: 10 jul. 2026.
- [6] S. R. Salomão, R. W. Cinoto, A. Berezovsky, A. Araújo-Filho, M. R. K. H. Mitsuhiro, L. Mendieta, P. H. A. Morales, G. P. Pokharel, R. Belfort Jr., and L. B. Ellwein, “Prevalence and causes of vision impairment and blindness in older adults in Brazil: the São Paulo Eye Study,” *Ophthalmic Epidemiology*, vol. 15, no. 3, pp. 167–175, 2008.
- [7] T. A. Chagas, M. A. dos Reis, G. Leivas, L. P. Santos, A. N. Gosseneheimer, G. B. Melo, F. K. Malerbi, and B. D. Schaan, “Prevalence of diabetic retinopathy in Brazil: a systematic review with meta-analysis,” *Diabetology & Metabolic Syndrome*, vol. 15, no. 1, p. 34, 2023.
- [8] J. De Fauw, J. R. Ledsam, B. Romera-Paredes *et al.*, “Clinically applicable deep learning for diagnosis and referral in retinal disease,” *Nature Medicine*, vol. 24, no. 9, pp. 1342–1350, 2018.
- [9] P. P. Srinivasan, L. A. Kim, P. S. Mettu, S. W. Cousins, G. M. Comer, J. A. Izatt, and S. Farsiu, “Fully automated detection of diabetic macular edema and dry age-related macular degeneration from optical coherence tomography images,” *Biomedical Optics Express*, vol. 5, no. 10, pp. 3568–3577, 2014.
- [10] A. Butola, D. K. Prasad, A. Ahmad, V. Dubey, D. Qaiser, A. Srivastava, P. Senthilkumaran, B. S. Ahluwalia, and D. S. Mehta, “Deep learning architecture LightOCT for diagnostic decision support using optical coherence tomography images of biological samples,” *Biomedical Optics Express*, vol. 11, no. 9, pp. 5017–5031, 2020.
- [11] R. Arefin, M. D. Samad, F. A. Akyelken, and A. Davanian, “Non-transfer deep learning of optical coherence tomography for post-hoc explanation of macular disease classification,” in *2021 IEEE 9th International Conference on Healthcare Informatics (ICHI)*, 2021, pp. 48–52.
- [12] I. E. Tampu, A. Eklund, and N. Haj-Hosseini, “Inflation of test accuracy due to data leakage in deep learning-based classification of OCT images,” *Scientific Data*, vol. 9, p. 580, 2022.

Tabela I

SÍNTESE DOS TRABALHOS MAIS DIRETAMENTE RELACIONADOS. RESULTADOS DE PROTOCOLOS, VERSÕES E UNIDADES DE AVALIAÇÃO DIFERENTES NÃO FORMAM UM RANKING ÚNICO.

Estudo	Abordagem	Dados e avaliação	Resultado e ressalva
Srinivasan et al. [9]	HOG multiescala e SVM	45 sujeitos; normal, DME e DMRI seca; avaliação por volume	100% para DME/DMRI e 86,67% para normal; tarefa menor e distinta
Kermany et al. [1]	Inception V3/ImageNet; convoluções congeladas	108.312 imagens de treino; teste independente com 1.000 B-scans	96,6% de acurácia; sensibilidade/especificidade publicadas referem-se à decisão urgente
Butola et al. [10]	LightOCT com duas convoluções, treinada do zero	Quatro classes; teste oficial com 1.000 B-scans	94,5%; desempenho próximo das redes pré-treinadas avaliadas
Arefin et al. [11]	CNN com cinco convoluções e duas camadas densas, sem transferência	Versão 2; teste oficial com 968 B-scans	97,9%; versão posteriormente associada a sobreposição entre treino e teste
Tampu et al. [12]	LightOCT sob diferentes estratégias de particionamento	Versões 2 e 3; divisão por imagem e por sujeito/volume	Inflação de 5–30 pontos percentuais; 92% de sobreposição na versão 2 e nenhuma na versão 3